

Национальный исследовательский университет «Высшая
школа экономики»

Московский государственный институт электроники и
математики
Компьютерная безопасность

Анализ социально экономических данных

Работу выполнил:

Коновалов Павел Олегович

Москва 2025

Оглавление

	2
Предварительный анализ данных	3
a) Постановка задачи.	3
b) Графическое представление исходных данных	3
c) Характеристики положения (mean, median, mode)	6
d) Характеристики разброса (размах, CV, дисперсия, стандартное отклонение)	6
e) Ранговые характеристики (квартили, децили)	7
f) Z-преобразование	7r
g) Расчёт межквартильной разницы (IQR)	7
h) 1,5 и 3 IQR; правило 3σ	7
i) Выводы	8
2. КОРРЕЛЯЦИОННЫЙ АНАЛИЗ	9
a) Построение полей корреляции между переменными	9
b) Описание силы, направления связи и выявление выбросов	12
c) Матрица парных коэффициентов корреляции (до удаления выбросов)	12
d) Очистка выборки от выбросов и повторная визуализация	13
e) Повторная матрица парных коэффициентов корреляции	16
f) Общие выводы о парной корреляции	17
g) Матрица частных коэффициентов корреляции	17
h) Сравнение парной и частной корреляции	18
i) Множественный коэффициент корреляции	18
j) Итоговые выводы по корреляционному анализу	18
3. Регрессионный анализ	19
a) Построение модели	19
b) Результаты регрессионной модели	19
c) Интерпретация коэффициентов	19
d) Визуализация модели	20
e) Вывод	20
4. Кластерный анализ	25
a) Построение и анализ дендрограмм	26
b) Выбор количества кластеров	26
c) Метод k-средних. Описание кластеров	27
d) Нормализация vs стандартизация	27
e) График средних значений и интерпретация кластеров	28
f) Типологическая регрессия по кластерам	28
g) Сравнение значимости и интерпретация	28

1. Предварительный анализ данных

а) Постановка задачи.

Описание показателей. Выдвижение рабочих гипотез

Постановка задачи

Необходимо исследовать социально-экономические данные по 85 регионам России, изучить особенности их распределений, выявить наличие выбросов и подготовить всё к дальнейшему корреляционному, регрессионному и кластерному анализам. В фокусе — взаимосвязи между уровнем доходов, масштабами добычи, безработицей и долей населения с доходами ниже ПМ.

Описание показателей


1. **population** — численность населения (чел.)
2. **income** — среднедушевые доходы (руб./мес.)
3. **unemployment_rate** — доля безработных (%)
4. **extraction** — добыча полезных ископаемых (млн руб.)
5. **poor_share** — доля населения с доходами ниже ПМ (%)

Рабочие гипотезы

1. «Чем выше **income**, тем ниже **poor_share**» (отрицательная связь).
2. «Объём **extraction** позитивно коррелирует с **income**» (ресурсные регионы имеют более высокие доходы).
3. «Сильные различия в **population** влияют на уровень безработицы и бедности»


б) Графическое представление исходных данных

1. Точечное распределение (Dotplot)




- **income**: основная масса значений 25–40 тыс. руб., 1–2 выброса за 90 тыс.
- **extraction**: для большинства регионов до 600 тыс. млн руб., но у 1–2 субъектов свыше 1 000 тыс. млн руб.
- **unemployment_rate**: «пучок» 2–5%, пара регионов выше 10%.

2. Листовая диаграмма (Stemplot)



- **population**: масса регионов 0,6–2 млн, одна «ветка» свыше 10 млн (Москва).
- **poor_share**: диапазон 5,9–30%, но основная часть 11–14%.

3. Диагностика выбросов (Boxplot)



- **extraction**: регионы с ~1,245 трлн руб. добычи — крайние точки.
- **income**: до 99,64 тыс. руб., заметный разрыв с медианой (33,15 тыс.).
- **unemployment_rate**: регион с 17,33% (экстремальный выброс).

с) Характеристики положения (mean, median, mode)

Показатель	Среднее (mean)	Медиана (median)	Мода (mode)
population	1 731 554	1 143 224	Не выделена
income	37 691 руб.	33 149 руб.	Нет чёткой
unemployment_rate	3,65%	3,01%	Нет чёткой
extraction	328 871 млн	290 992 млн	Нет чёткой
poor_share	13,33%	13,40%	Нет чёткой

- Для **income** медиана < среднего, что говорит о правосторонней асимметрии.
- Мода у непрерывных показателей обычно отсутствует.

d) Характеристики разброса (размах, CV, дисперсия, стандартное отклонение)

1. **Размах**

- population: от 41 434 до 13 010 110 (разница ~12,97 млн).
- income: 20 978–99 640 (разница 78 662 руб.).
- unemployment_rate: 0,205–17,333% (разница ~17,13 п.п.).
- extraction: 337–1 245 793 млн руб. (разница 1 245 456).
- poor_share: 5,9–30% (разница 24,1 п.п.).

2. **Коэффициент вариации ($CV = \sigma/\text{mean} \times 100\%$)**

- population ~109%
- income ~42,5%
- unemployment_rate ~66%
- extraction ~93,4%
- poor_share ~28,4%

3. **Дисперсия, стандартное отклонение**

- Широкий разброс особенно у «population» и «extraction».

е) Ранговые характеристики (квартили, децили)

Показатель	Q1	Q3	IQR = Q3 – Q1
population	687 357	2 163 693	1 476 336
income	28 697 руб.	38 104 руб.	9 407 руб.
unemployment_rate	2,545%	3,857%	1,312 п.п.
extraction	24 188 млн	581 774 млн	557 586
poor_share	11,6%	13,9%	2,3 п.п.

- Децили (D1, D9 и т. д.) можно считать при необходимости более детального анализа.

ф) Z-преобразование

Для устранения влияния разных единиц измерения (руб., % и т. д.) проведено стандартное Z-преобразование:

- Каждая переменная получает среднее 0 и std=1.
- Это потребуется для корректной регрессии и кластеризации.

г) Расчёт межквартильной разницы (IQR)

Из таблицы (п. е):

- **income**: IQR = 9 407 руб.
- **extraction**: IQR = 557 586 (тыс. млн руб.) и т. д.

h) Выявление выбросов по статистическим правилам

Для выявления выбросов в данных использовались три метода: правило $1,5 \cdot IQR$, правило $3 \cdot IQR$ и правило 3σ . Эти методы позволяют определить, какие значения переменных существенно выбиваются из общей выборки.

1. Правило $1,5 \cdot IQR$ (межквартильный размах)

Для каждой переменной рассчитываются границы выбросов по формулам:

- Нижняя граница:

$$Q1 - 1,5 \times IQR$$

- Верхняя граница:

$$Q3 + 1,5 \times IQR$$

Где:

- $Q1$ и $Q3$ — первый и третий квартиль,
- $IQR = Q3 - Q1$ — межквартильный размах.

Наблюдения, выходящие за эти границы, считаются **умеренными выбросами**.

2. Правило $3 \cdot IQR$

- Нижняя граница:

$$Q1 - 3 \times IQR$$

- Верхняя граница:

$$Q3 + 3 \times IQR$$

Наблюдения, выходящие за эти границы, считаются **экстремальными выбросами**.

3. Правило 3σ (3 стандартных отклонения)

Если переменная имеет распределение, близкое к нормальному, применяется правило трёх сигм:

- Границы:

$$\bar{X} \pm 3\sigma$$

Где:

- $\bar{X}$ — среднее значение переменной,
- σ — стандартное отклонение.

Выводы:

- Во всех переменных (особенно *доход, добыча, безработица*) обнаружены выбросы.
- Некоторые значения выходят за пределы $1,5 \cdot IQR$ и даже $3 \cdot IQR$, что делает их статистически значимыми аномалиями.
- Выбросы могут искажать результаты анализа, поэтому дальнейшие методы (корреляция, регрессия) желательно проводить как **с выбросами**, так и **без них** для сравнения.
- Для наглядного отображения выбросов использовались **ящичковые диаграммы (boxplot)**, визуально показывающие границы IQR и отклоняющиеся значения.

i) Выводы

1. **Высокий разброс** по населению и добыче ($CV > 90\%$). Доход и безработица тоже довольно вариабельны, но чуть меньше.
2. **Выбросы:**
 - Безработица: 17,33% (крайний случай).
 - Доходы: регион ~99,64 тыс. руб. далеко «уходит» от медианы (33,15 тыс.).
 - Добыча: 1–2 лидирующих субъекта с >1 трлн руб.
3. **Правосторонняя асимметрия** у income и extraction подтверждается медианой, значительно меньше средней.
4. **Z-преобразование** сделано для каждого признака, чтобы уравнивать масштабы.
5. Данные готовы к углубленному анализу: **корреляционному, регрессионному и кластерному**.

Таким образом, мы выяснили ключевые особенности распределений, выявили аномальные наблюдения и сформировали основу для дальнейших этапов работы.

2. Корреляционный анализ

Целью данного этапа анализа является выявление характера, направления и силы взаимосвязей между ключевыми социально-экономическими показателями в регионах Российской Федерации. Проведение корреляционного анализа помогает определить, какие из факторов в наибольшей степени связаны с уровнем социального неблагополучия, который в данной работе представлен переменной «Доля населения с доходами ниже прожиточного минимума».



Исследование начинается с визуального анализа, переходит к количественным оценкам (с использованием коэффициентов корреляции Пирсона), а также включает удаление выбросов для повышения надёжности выводов. Итогом является уточнённая картина взаимосвязей, а также подготовка к регрессионному моделированию.

а) Построение полей корреляции между переменными

Первым шагом было построение **диаграмм рассеяния (scatter plots)** между зависимой переменной (доля населения с доходами ниже ПМ) и всеми количественными признаками, доступными в выборке:

- **Среднедушевые доходы населения** (в рублях),
- **Уровень безработицы** (%),
- **Объём добычи полезных ископаемых** (млн рублей),
- **Численность населения региона** (в чел.).

Цель построения этих графиков — визуально оценить, имеется ли линейная или нелинейная зависимость между показателями, а также обнаружить возможные **аномальные наблюдения (выбросы)**, которые в будущем могут повлиять на точность корреляционного анализа.



Комментарий к графикам:

На большинстве диаграмм видна выраженная тенденция: например, при росте доходов доля бедного населения уменьшается. В то же время на некоторых графиках (особенно «Добыча ПИ – Доля ниже ПМ») зависимость визуально слабая или отсутствует.

б) Описание силы, направления связи и выявление выбросов


После визуального анализа были сформулированы первичные гипотезы:

- **Доход и бедность:** наблюдается **отрицательная зависимость**, т.е. чем выше доход, тем меньше доля бедных.
- **Безработица и бедность:** положительная зависимость — при росте безработицы увеличивается бедность.
- **Добыча полезных ископаемых и бедность:** связь либо очень слабая, либо отсутствует.
- **Численность населения и бедность:** умеренно выраженная отрицательная связь.

На основании графиков были также обнаружены **наблюдения, резко выделяющиеся** из общей картины. Такие точки могут исказить статистические показатели. Для их последующей фильтрации применён метод межквартильного размаха (IQR), который позволяет объективно определить границы допустимых значений.

с) Матрица парных коэффициентов корреляции (до удаления выбросов)

На следующем этапе была рассчитана **матрица коэффициентов корреляции Пирсона**. Эта матрица показывает уровень линейной связи между каждой парой переменных.




Основные наблюдения:



- Доход и бедность: коэффициент -0.35 (умеренная обратная связь),
- Безработица и бедность: $+0.57$ (достаточно сильная прямая связь),
- Население и бедность: -0.40 (умеренная обратная связь),
- Добыча ПИ и бедность: -0.16 (слабая связь).


Также видно, что между независимыми переменными **отсутствует мультиколлинеарность** — все коэффициенты между ними значительно меньше 0.7.

d) Очистка выборки от выбросов и повторная визуализация

Для повышения точности анализа были удалены выбросы на основе метода IQR. После очистки выборки были повторно построены scatter-поля, чтобы оценить изменения в распределении точек.








Комментарий к результату:

После удаления выбросов облако точек стало более компактным, линейные зависимости — более выраженными. Особенно это заметно для зависимости между доходом и бедностью.

е) Повторная матрица парных коэффициентов корреляции

После удаления выбросов была заново рассчитана корреляционная матрица. Отмечены следующие изменения:



Пара	До очистки	После очистки	Изменение
Доход – Бедность	–0.35	–0.41	усилилась
Безработица – Бедность	+0.57	+0.42	ослабла немного
Население – Бедность	–0.40	–0.23	ослабла
Добыча ПИ – Бедность	–0.16	–0.16	без изменений

f) Общие выводы о парной корреляции

- Наиболее устойчивой связью остаётся связь между доходом и бедностью.
- Связь между безработицей и бедностью также сохраняется, но частично ослабла.
- Численность населения и добыча ПИ в меньшей степени объясняют уровень бедности.
- Выбросы влияют на оценку силы связи — это подчёркивает необходимость предварительной очистки данных.

g) Матрица частных коэффициентов корреляции

Для уточнения вклада каждой переменной была проведена оценка **частных коэффициентов корреляции** — т.е. связи между признаком и бедностью при условии фиксации остальных переменных.

Признак	Частная корреляция
Доход_в_месяц_руб	-0.308
Безработица_проц	0.316
Добыча_ПИ_млн_руб	-0.108
Население	-0.068

Результаты интерпретации:

- Частная корреляция дохода с бедностью снизилась по сравнению с парной — влияние частично опосредовано другими факторами.
- Безработица сохранила устойчивую положительную связь.
- Остальные переменные показали снижение силы связи после учёта других факторов.

h) Сравнение парной и частной корреляции

- Если частная корреляция меньше парной, значит, на связь влияют другие переменные (влияние опосредованное).
- Если частная примерно равна парной, признак оказывает прямое влияние.
- Если частная больше парной — может наблюдаться эффект подавления.

По нашему анализу:

- Доход частично связан с бедностью через безработицу.
- Безработица сохраняет прямое влияние.

i) Множественный коэффициент корреляции

Завершающим этапом анализа стал расчёт **множественного коэффициента корреляции (R)** между бедностью и всеми остальными признаками одновременно. Это позволило оценить, насколько хорошо совокупность факторов объясняет колебания уровня бедности.

Результаты (на очищенной выборке):

- $R = 0.71$
- $R^2 = 0.50$ → объясняется 50% дисперсии бедности
- F-критерий: значим, $p < 0.01$

Комментарий:

Это говорит о том, что модель на основе уровня доходов, безработицы и численности населения может **объяснить половину изменчивости бедности по регионам**.

j) Итоговые выводы по корреляционному анализу

- Доход и безработица являются ключевыми детерминантами бедности.
- После удаления выбросов картина зависимостей стала более прозрачной.
- Частные коэффициенты подтвердили: на бедность влияет совокупность факторов, но безработица оказывает наиболее устойчивое влияние.
- Множественная корреляция показала хорошее объясняющее качество модели — более 50%.

3. Регрессионный анализ

а) Построение модели

В качестве зависимой переменной выбран показатель **среднедушевых доходов в месяц (руб.)**. В роли объясняющих переменных выступают:

- Доля населения с доходами ниже ПМ (2020, %)
- Доля безработных (%)

Выбор этих факторов обусловлен их высокой социальной значимостью и предполагаемым влиянием на уровень доходов населения. Анализ проводится методом множественной линейной регрессии (OLS).

б) Результаты регрессионной модели

Показатель	Значение
Коэффициент детерминации (R^2)	0.124
Скорректированный R^2	0.103
F-статистика	5.81
p-value модели	0.004
Множественный коэффициент корреляции (R)	0.352


Модель статистически **значима** ($p\text{-value} < 0.05$), что позволяет отвергнуть гипотезу о нулевых коэффициентах при всех признаках.

с) Интерпретация коэффициентов

Переменная	Коэффициент	p-value	Значимость
Константа	57115.33	<0.001	значима
Доля безработных (%)	-290.09	0.729	незначима
Доля населения с доходами ниже ПМ (%)	-1377.91	0.011	значима

Интерпретация: при увеличении доли населения с доходами ниже прожиточного минимума на 1 процентный пункт, среднедушевой доход снижается в среднем на **1378 рублей в месяц**. Влияние безработицы статистически не подтверждено.

д) Визуализация модели





- **График остатков** показал наличие выбросов и возможную гетероскедастичность.
- **QQ-график остатков** демонстрирует отклонения от нормального распределения.
- **График фактических и предсказанных значений** выявил, что модель хорошо описывает центральные значения, но недооценивает высокие доходы.

е) Вывод

Модель демонстрирует наличие **социально обусловленного снижения доходов** в регионах с высоким уровнем бедности. Как и в примере из контрольной работы, основным значимым фактором остаётся именно **доля бедного населения**, тогда как уровень безработицы не оказывает статистически значимого влияния в данной модели.

4. Кластерный анализ





Целью кластерного анализа является классификация 85 регионов России по сходству социально-экономических характеристик с использованием иерархической и неиерархической кластеризации (метод k-средних).

а) Построение и анализ дендрограмм

Для иерархической кластеризации использовались следующие меры агломерации (расстояние — евклидово, данные стандартизованы):

1. Метод ближнего соседа (*single linkage*)
2. Метод дальнего соседа (*complete linkage*)
3. Метод средней связи (*average linkage*)
4. Метод центра тяжести (*centroid linkage*)
5. Метод Уорда (*Ward linkage*)

По результатам анализа дендрограмм наилучшую интерпретируемость и устойчивость показал **метод Уорда**, минимизирующий внутрикластерную дисперсию. Этот метод выбран для дальнейшего разбиения.

б) Выбор количества кластеров

На основе дендрограммы метода Уорда оптимальным представляется деление на **4 кластера**. При уровне расстояния около 6 наблюдается заметный разрыв

между объединяющимися ветвями, что соответствует естественному «срезу» дендрограммы.

Допустимыми альтернативами были варианты с 3 или 5 кластерами, однако они показали менее чёткую структуру и менее равномерный состав.

с) Метод k-средних. Описание кластеров

По результатам иерархической кластеризации выполнена кластеризация методом **k-средних** при $k=4$. Входные данные были предварительно **стандартизованы** (Z-преобразование). Расстояние между наблюдениями рассчитывалось по **евклидовой метрике**.

Средние значения показателей в кластерах:

Кластер	Население	Доходы	Безработица	Добыча	Бедность
Кластер 1	1,04 млн	46 771 руб.	2,86 %	620 млрд руб.	11,97 %
Кластер 2	701 тыс.	27 466 руб.	9,94 %	319 млрд руб.	22,60 %
Кластер 3	9,05 млн	69 153 руб.	1,22 %	512 млрд руб.	6,23 %
Кластер 4	1,80 млн	31 706 руб.	3,48 %	149 млрд руб.	13,40 %

Интерпретация кластеров:

- **Кластер 1** — «Устойчивые регионы»: умеренные доходы, низкая безработица, бедность ниже средней.
- **Кластер 2** — «Кризисные регионы»: самая высокая бедность и безработица, низкие доходы.
- **Кластер 3** — «Мегаполисы»: крупные регионы с высокими доходами, низкой бедностью и безработицей.
- **Кластер 4** — «Средний класс»: показатели вблизи среднероссийских.

d) Нормализация vs стандартизация

Было решено использовать **z-преобразование**, так как переменные находятся в разных шкалах (рубли, %, чел., млн руб.). Использование min-max нормализации привело бы к искажению результатов из-за наличия выбросов.

Стандартизация позволила уравнивать влияние всех признаков.

e) График средних значений и интерпретация кластеров

Профили кластеров отражены на графике средних значений по 5 показателям. На его основе сформулированы **названия и интерпретации кластеров**:

- **Кластер 1** – «Устойчивые регионы»
- **Кластер 2** – «Наименее благополучные»
- **Кластер 3** – «Богатые мегаполисы»
- **Кластер 4** – «Средний класс»

(График можно разместить после таблицы кластеров.)

f) Типологическая регрессия по кластерам

Для каждого из 4 кластеров была построена отдельная регрессия, где:

- **Зависимая переменная (Y)**: доля населения с доходами ниже ПМ (*poor_share*)
- **Независимые переменные (X)**: доход (*income*), безработица (*unemployment_rate*), добыча (*extraction*)

Результаты по кластерам:

- **Кластер 1**
 - $R^2 = 0,025$ — модель незначима
 - Все коэффициенты незначимы ($p > 0,2$)
- **Кластер 2**
 - $R^2 = 0,846$ — модель высоко значима
 - Значим только доход (отрицательная связь, $p < 0,01$)
- **Кластер 3**
 - $R^2 = 1,000$ — модель описывает данные идеально, но в кластере всего 3 региона → низкая надёжность
- **Кластер 4**
 - $R^2 = 0,171$ — слабая модель
 - Доход значим ($p = 0,008$), остальные переменные — нет

g) Сравнение значимости и интерпретация

- В кластерах **2 и 4** доход оказался статистически значимым фактором, влияющим на уровень бедности.
- В **кластере 1** (умеренные регионы) и **кластере 3** (мегаполисы) зависимость не выявлена.
- **Безработица и добыча** не показали устойчивой значимости ни в одном из кластеров.
- Таким образом, **влияние доходов на бедность** подтверждается в регионах с более выраженными социальными проблемами, тогда как в успешных регионах этот фактор менее критичен.

Итог

Анализ показал, что ключевыми факторами, связанными с уровнем бедности в регионах, являются среднедушевые доходы и уровень безработицы. Доходы оказывают обратное влияние — при их росте доля бедного населения снижается, тогда как безработица оказывает прямое воздействие. Другие переменные, такие как численность населения и добыча ПИ, показали слабую или неустойчивую связь.

Удаление выбросов позволило уточнить силу связей, а частные корреляции подтвердили самостоятельную значимость дохода и безработицы. Результаты могут быть использованы для разработки региональной политики по снижению бедности.